AIに帳票の解釈と編集を任せる

実装した反復処理と、3モデルを使った検証結果

書式を読む。コードを実行する。
結果を見て、編集を進める。

大学別のセル対応表を渡さず、既存のExcelを記入した。

Solの完了・静的合格

12 / 12

実験全体の費用推計

$2.9245

同じ4つの基本ケースを反復。費用はusageによる推計で、確定請求額との照合は未実施。

方針転換で変えたこと

帳票ごとの判断と編集コードを、実行時のAIに任せる

これまでの想定

会計データ
規定のデータを用意

→

大学別の変換・配置ロジック
開発者が分類・集計・セル対応を実装

→

出力ファイル
実装した規則で生成

今回のPoC

Excelと取引JSON
書式と事実を渡す

→

AIが調べて、その場で編集
意味・記入位置・手法を判断し、コードを実行

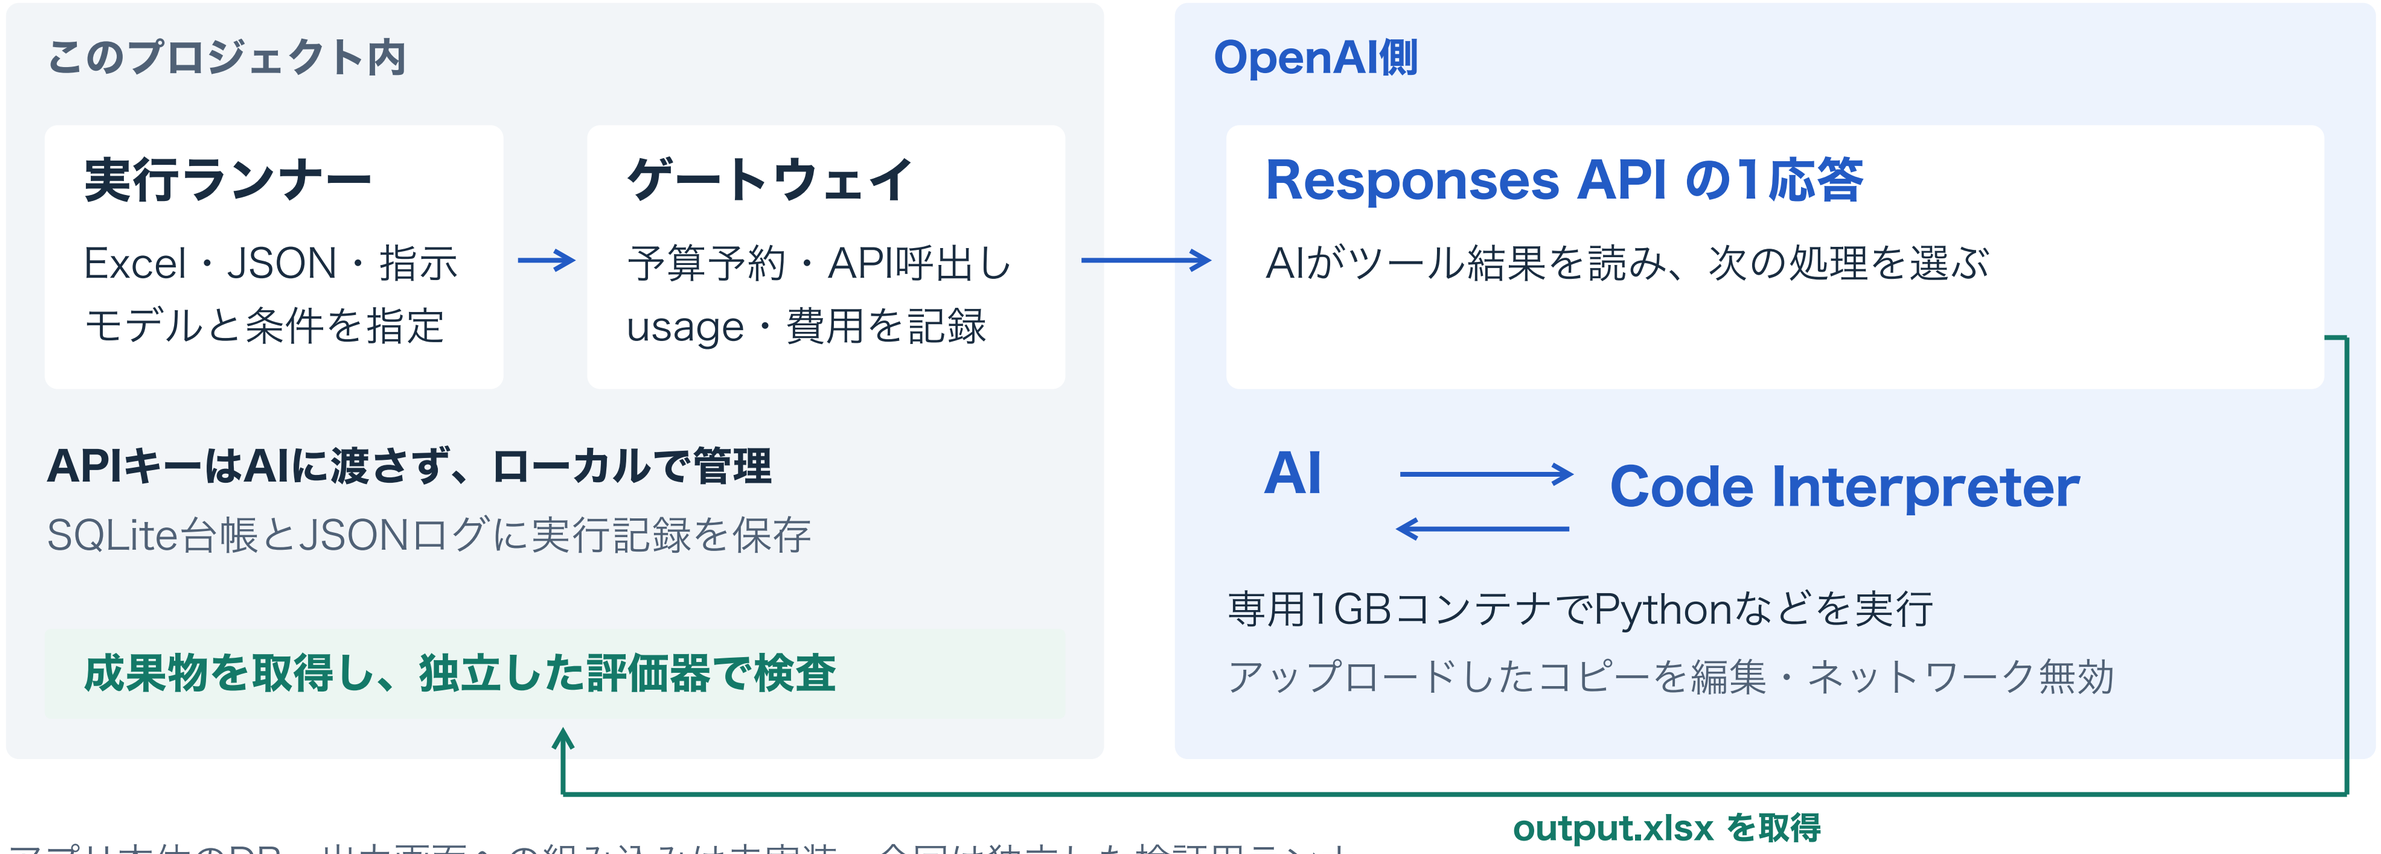
→

編集済みExcel
別の評価器で検査

正しさの基準は評価側に残す。モデルには採点用の正解やセル対応を渡していない。

実装の全体構成

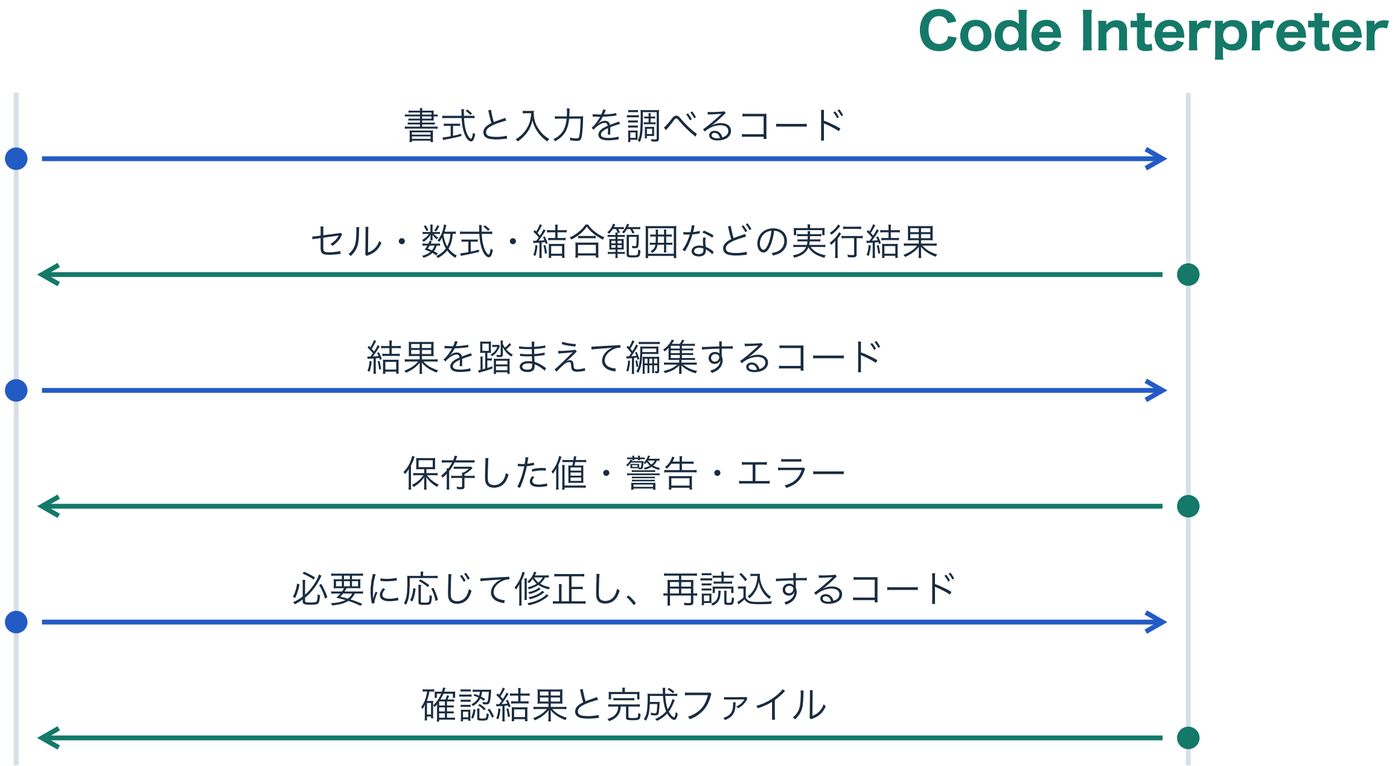
ローカルの計測と、AIが編集する隔離環境を分ける



アプリ本体のDB・出力画面への組み込みは未実装。今回は独立した検証用ランナー。

AIとツールのやり取り

1試行につき1回のResponses API呼出し。その内部で実行と確認を繰り返す



実行結果を次の判断に使うことが、今回のinteractiveな編集

独立評価器の結果をAIへ自動で戻すループや、利用者向けの会話画面はまだない。

実際の反復例：Sol × 学習院

1回のAPI応答の中でCode Interpreterを11回実行。所要時間104.344秒

1	**調べる**	全シート、数式、結合セル、図形、印刷設定を読む
2	**編集する**	必要なXMLを部分編集し、小計の数式を6つ追加する
3	**結果を確かめる**	使い捨てコピーを再計算するが、保存済みの計算値が0のまま
4	**方法を修正する**	計算値を消して再計算を促し、ZIPを書き込む処理も修正する
5	**保存物を読み直す**	計算結果を元の構造へ戻し、値・式・ZIP差分を確認する
6	**成果物を返す**	Excelへのリンクと、変更点・使った環境・未確認事項を返す

収入の部計 ¥30,000　実支出 ¥5,000　次年度繰越 ¥25,000　／　独立した静的検査に合格

API費用をゲートウェイで計測

再起動しても同じSQLite台帳と、実験全体の$10予算を引き継ぐ

送信前
保守的な金額を予約

→

呼出し
要求・応答を記録

→

応答後
usageから推計を精算

→

終了時
ファイルと環境を削除

記録するもの

モデル・設定・入力と指示のハッシュ

入力／出力／キャッシュのトークン数

提供元の識別子・失敗・後片付けの結果

過小計上を防ぐルール

費用が分からなければ、予約を残す

自動リトライで同じ試行を重ねない

内部ツール回数でコンテナ費用を増やさない

usageと固定単価による推計。提供元の確定請求額との照合は別途行う。

比較した条件

モデル以外の条件を揃え、同じ基本ケースを3回ずつ実行した

4書式 × **3モデル** × **3回** = **36**

立命館・学習院・法政・早稲田

モデル

gpt-6.1-sol
gpt-6-luna
gpt-5.6-luna

共通条件

出力上限8,000トークン・reasoning medium
1試行1応答・新しい専用1GBコンテナ
直列実行・自動リトライなし

別枠：保存対照4応答 ＋ 追加条件4応答 ＋ 接続確認3応答　　合計47応答

合格と完了を分けて確認

ファイル内の値だけで、成功とは判定しない

静的合格

内容

金額・分類・識別番号・明細など

構造と保持

数式・対象外シート・図形・コメント

入力規則・印刷設定・XMLの整合性

完了した成果物

1. 提供元の応答が completed
2. 空でない最終回答も完了
3. Excelを取得できる
4. 独立した静的検査に合格

Excelで開く・再計算する・印刷する確認は、さらに別の検証

評価器は出力を見た後に訂正した。元の評価を残し、全取得済み成果物へ同じ基準を適用。
事前に完全固定したベンチマークではない点も、結果の限界として記録した。

Solが12回すべてで合格・完了

固定条件の36試行。追加条件の4試行は、この表へ含めない

モデル	静的合格	合格・完了	平均費用／試行	時間中央値
gpt-6.1-sol	**12 / 12**	**12 / 12**	$0.1354	77.2秒
gpt-6-luna	**1 / 12**	**0 / 12**	$0.0373	97.2秒
gpt-5.6-luna	**1 / 12**	**1 / 12**	$0.0414	81.1秒

失敗分を含む「合格・完了1件」の費用：Sol $0.1354 ／ 5.6 Luna $0.4973

6 Lunaは合格・完了0件のため単価を算出できない。時間は失敗も含み、後片付けを除く。

金額が合っていても、帳票は壊れる

保存手法の選択と、見える位置・構造の確認が必要だった

01 保存しただけで図形が消える

openpyxl対照：4書式で機能・表現の欠落。法政では説明用図形22個が消失。

02 正しい文字列が、表示されない位置に入る

C28：結合範囲の左上	D28：結合の内部
団体コードNO.	**007**

模式図。破線は説明用で、Excelで見えるセル境界ではない。

6 Lunaの学習院では、正しいコードをD28へ記入。
結合されたC28:D28では、その値が表示されない。

03 XML編集でセルを削除・移動してしまう

5.6 Lunaの早稲田では、実際のExcelがファイルの修復を要求した。

図形・コメント・入力規則の保持と、OOXMLの整合性を、金額の検査と分けて確認する。

追加条件でも、課題が残った

失敗ケースに対する新規試行を4回。前回の成果物や履歴は渡していない

変更した条件	対象	観察した結果
6 Luna：上限12,000	学習院	上限到達。ダウンロード可能な成果物なし。
6 Luna：上限12,000	早稲田	成果物は静的合格。最終回答は上限で途中終了。
5.6 Luna：保持指示	法政	金額・数式・22図形は保持。 接頭辞の宣言が欠け、構造検査で不合格。
5.6 Luna：保持指示	早稲田	式・パーツは保持。 意味が未確定の日付欄を埋めてしまい不合格。

4回とも「合格・完了」の全条件には到達しなかった

各条件・各書式1回だけの観察。主比較の成功率へ混ぜず、改善率の推定にも使わない。

実験全体の費用は、推計$2.9245

47回のResponsesを同じ台帳で計測。予算$10内で終了した

$2.9245

使用量に基づく推計額



トークン
$1.6045

コンテナ44個
$1.3200

未使用の予算 $7.0755

内訳

基本比較 36応答	$2.5702
保存対照 4応答	$0.1847
追加条件 4応答	$0.1695
接続確認 3応答	$0.0001

未解決費用・残予約 0

確定請求額との照合は未実施。税・為替・人の調査や確認作業・本番運用費は含まない。

生成したExcelを、実際のExcelでも確認

学習院・Sol初回の印刷証拠。モデルの元成果物を変更せず、コピーで検査した



1

令和7年度 輔仁会大学支部合成会計検証部 会計報告書

収入の部			支出の部		
費 目	金 額	備 考	費 目	金 額	備 考
前年度繰越金	10,000		備品費	3,000	5/1 収納棚
輔仁会予算	0		消耗品費	1,200	
助成金	0		ボール代	0	
			筆記用具	1,200	5/2 マーカー
			運搬費	0	
			交通費	0	
			通信費	0	
			連盟登録費	0	
			試合参加費	0	
			春リーグ戦	0	
			秋リーグ戦	0	
			関東学生選手権	0	
			全日本学生選手権	0	
部費	20,000		全日本選手権	0	
4月徴収	10,000	2025/4/10			
10月徴収	10,000	2025/10/10	合宿遠征費	0	
合宿遠征費等個人負担金	0		夏季合宿	0	
			甲南戦	0	
			春季合宿	0	
			印刷費	800	5/3 活動資料
OB・OG会からの補助	0		雑費	0	
預金利子	0		次年度繰越金	25,000	
収入の部合計	30,000		支出の部合計	30,000	

団体コードNO. 007 団体名 合成会計検証部

記載責任者 文学部 史学科 2年 氏名：検証 花子

連絡先TEL: 000-0000-0000

学習院・初回の出力

部費の入力を ¥10,000 から
¥10,050 に変更すると、
総計も ¥30,050 に更新。

修復ダイアログなし
A4横1ページのPDFを確認

Sol初回の4書式で再計算を確認。
全体の表示・PDF確認は2書式。
全試行の提出品質を保証するものではない。

次の候補は、Solによる下書き生成

今回の4基本ケースでは、AI自身に帳票の解釈と編集を任せられた

人が差分と未確認事項を確認する運用を、次の検証対象にする

1	**評価を固定して広げる**	未見の取引、不足情報、長文、明細枠超過を追加する
2	**共通の編集操作を検証する**	結合セル・名前空間・ZIPパーツを安全に扱う手段を比べる
3	**人との対話を実装する**	質問、変更案の確認、追加指示による再編集を設計する

今回まだ作っていないもの：利用者向け会話画面、DB連携、アプリの出力API、自動提出。